

Trabalho 1: Regressão Linear com Múltiplas Variáveis

1st Nycksandro Lima dos Santos
Instituto de Computação
Universidade Federal do Amazonas
Manaus, Brasil
nycksandro.santos@icomp.ufam.edu.br

Abstract—Este trabalho apresenta a implementação e análise do algoritmo Adaline (Adaptive Linear Neuron) e a utilização do método da pseudo-inversa aplicado ao problema de regressão linear múltipla. Utilizou-se a base de dados hospitalar do MATLAB, composta por 100 amostras, para prever a pressão arterial sistólica a partir de variáveis como idade, peso, sexo e hábito tabagista. O processo metodológico incluiu a padronização dos dados via Z-Score e a aplicação de validação cruzada em cinco pastas para garantir a robustez dos resultados.

Index Terms—Adaline, Regressão Linear Múltipla, Dados hospitalares, Pseudo-Inversa, Validação Cruzada, Normalização Z-Score.

I. INTRODUÇÃO

Este trabalho descreve a implementação de um modelo de regressão linear baseado na rede neural Adaline para a estimativa da pressão arterial sistólica (máxima). Utilizou-se uma base de dados hospitalar contendo 100 registros, cujos atributos de entrada incluem sexo, idade, peso e a condição de fumante. A modelagem visa identificar o comportamento da variável dependente frente às oscilações das variáveis independentes selecionadas. Adicionalmente, os resultados obtidos pelo treinamento iterativo do Adaline são comparados à solução analítica da pseudo-inversa.

II. TRABALHOS SIMILARES

Foi realizada uma breve busca por trabalhos similares na literatura, e foram selecionados 2 artigos:

A. A new machine learning method for predicting systolic and diastolic blood pressure using clinical characteristics

O artigo científico [1] apresenta um novo método de aprendizado de máquina para prever as pressões arteriais sistólica e diastólica com base em características clínicas e hábitos de vida. Os pesquisadores utilizaram uma base de dados com 50.000 registros para treinar modelos que consideram variáveis como idade, peso, tabagismo e níveis de colesterol. Foram testados quatro algoritmos distintos: KNN, regressão logística, árvore de decisão e random forest.

O estudo conclui que o modelo de random forest atingiu o nível mais alto de precisão e eficiência computacional. Essa abordagem busca facilitar o diagnóstico precoce da hipertensão, reduzindo a necessidade de equipamentos caros ou intervenção humana constante.

B. A Linear Regression Model with Dynamic Pulse Transit Time Features for Noninvasive Blood Pressure Prediction

O estudo de Hsieh et al. [2] propõe um modelo de regressão linear (LR) aprimorado para a predição não invasiva das pressões arterial sistólica (SBP) e diastólica (DBP). A principal inovação do método consiste na inclusão de características dinâmicas (como inclinação e curvatura) extraídas do Tempo de Trânsito do Pulso (PTT), além das características estáticas convencionais.

Os autores também introduziram uma abordagem onde o valor estimado da pressão sistólica é utilizado como parâmetro adicional para aumentar a precisão na predição da pressão diastólica. Testado com dados da base MIMIC, o modelo proposto (LR-SD) demonstrou desempenho superior aos métodos tradicionais, apresentando maiores coeficientes de correlação (R^2) e menores erros quadráticos médios (MSE).

Apesar da eficácia, o trabalho ressalta que o modelo possui limitações para capturar oscilações de baixa frequência influenciadas por fatores internos e externos, o que torna a recalibração periódica necessária para manter a acurácia a longo prazo.

III. BASE DE DADOS

	ID	LastName	Sex	Age	Weight	Smoker	BloodPressure_1	BloodPressure_2	Trials_1	Trials_2	Trials_3	Trials_4
0	YPL-320	SMITH	Male	38	176	True	124	93	18.0	NaN	NaN	NaN
1	GLI-532	JOHNSON	Male	43	163	False	109	77	11.0	13.0	22.0	NaN
2	PNI-258	WILLIAMS	Female	38	131	False	125	83	NaN	NaN	NaN	NaN
3	MJJ-579	JONES	Female	40	133	False	117	75	6.0	12.0	NaN	NaN
4	XLK-030	BROWN	Female	49	119	False	122	80	14.0	23.0	NaN	NaN

Fig. 1. As primeiras 5 linhas da base de dados hospitalar, demonstrando as colunas e algumas características dos dados.

A base de dados utilizada nesse trabalho possui as seguintes características:

- Informações de Identificador, Último nome, Sexo, Idade, Peso, Se fuma ou não, Pressão Máxima e Mínima e estudos clínicos (até 4 amostras).
- 100 registros de pacientes
- 53 Mulheres e 47 Homens
- 34 Fumantes e 66 Não Fumantes
- Idade média de 38.28 anos
- Peso médio de 154 Libras (69,85 kg)




Fig. 2. Fluxograma da metodologia adotada para o trabalho prático.

IV. METODOLOGIA

A. Pré-processamento dos dados

1) *Limpeza de Colunas*: As colunas “Trials_1”, “Trials_2”, “Trials_3” e “Trials_4” além de possuírem diversos valores ausentes, também não são relevantes para predição da pressão máxima, uma vez que somente serão necessárias somente as colunas “Sexo”, “Idade”, “Peso” e “Fumante/Não Fumante”. Além das colunas “Trials”, as colunas “BloodPressure_2” (Pressão mínima), “ID” e “LastName” também não são necessárias para predizer o valor da pressão máxima de um paciente. Com isso, todas essas colunas desnecessárias para a predição foram retiradas do dataframe utilizado para o treinamento.

2) *Normalização*: As colunas “Age”, “Weight”, “BloodPressure_1” foram normalizadas para garantir um melhor aprendizado. Essa etapa é realizada após a aplicação da validação cruzada em 5 pastas para evitar vazamento de dados, e para isso, foi realizado os seguintes passos:

Para cada versão de Dataset (1-5) e para todas as colunas que precisam ser normalizadas:

- 1) Calcular a média (μ) e desvio padrão da partição de Treino (σ)
- 2) Para cada linha da coluna da partição de Treino selecionada, calcular o número normalizado (z) a partir da seguinte fórmula:

$$z = \frac{x - \mu}{\sigma} \quad (1)$$

Onde:

- x : Valor original.
- μ : Média da coluna.
- σ : Desvio padrão da coluna

- 3) Substituir x na linha da partição de Treino por z
- 4) Na partição de Teste e na linha equivalente a da partição de Treino, calcular z utilizando as médias e desvio padrão da partição de Treino
- 5) Substituir x na linha da partição de Teste por z

A normalização foi realizada após a divisão dos datasets para evitar vazamento de dados. Ao realizar essa etapa antes da divisão, o bloco de treino já conheceria qual é a média global (que inclui os dados do Teste), e isso inviesaria o treino.

3) *Codificação*: Transformar as variáveis categóricas “Sexo” em binárias (0/1). A coluna “Smoker” já está numérica (0 ou 1).

B. Divisão do Dataset

A divisão do dataset foi realizada seguindo a distribuição da Figura 3.

Como o dataset possui 100 registros e é necessário dividir em 5 partições (4 de treino e 1 de teste), com 20% dos registros

Validação cruzada



UFAM

Disciplina: Reconhecimento de Padrões

Prof. Cicero F F Costa Filho

Fig. 3. Ilustração da divisão do Dataset em validação cruzada de 5 pastas. Disponível em: [3]

cada, o número de registros que cada partição terá será de 20 registros (20% do total de 100 registros).

C. Treinamento

Para a realização do treinamento do modelo Adaline, os pesos w foram inicializados com valores nulos (zeros). O processo seguiu uma abordagem iterativa baseada na Regra de Delta, onde, a cada época, o vetor de pesos é atualizado de acordo com o gradiente do erro médio quadrático.

O treinamento foi configurado com uma taxa de aprendizado fixada em $\eta = 0.01$ e um limite de 15000 épocas, garantindo a convergência dos pesos para valores que minimizam a diferença entre a pressão arterial real (y) e a estimada ($\hat{y}$). Adicionalmente, aplicou-se a técnica de validação cruzada para assegurar a generalização do modelo, onde a base de dados foi dividida em cinco subconjuntos, alternando-se os dados de treino e teste em cada rodada.

D. Cálculo das métricas

1) *Erro Médio Quadrático (Mean Square Error – MSE)*: Erro Médio Quadrático é a função de custo fundamental para o treinamento do algoritmo Adaline. Ele quantifica a performance do modelo calculando a média aritmética dos quadrados das diferenças entre os valores reais (y) e as saídas estimadas ($\hat{y}$). Matematicamente, o MSE é definido pela equação

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (2)$$

Fonte: [4]

2) *Coefficiente de Pearson*: O Coeficiente de Pearson é uma medida estatística que quantifica o grau de relação linear entre duas variáveis quantitativas. No contexto deste trabalho, ele é utilizado para avaliar a correlação entre as características do paciente (variáveis independentes) e a pressão arterial sistólica (variável dependente). A fórmula matemática é dada por:

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}} \quad (3)$$

Onde $\hat{x}$ e $\hat{y}$ representam as médias aritméticas das respectivas variáveis.

Fonte: [5]

V. RESULTADOS

Após as 15.000 épocas do treinamento, foram calculados o Erro Médio Quadrático e o Coeficiente de Person. Os valores obtidos foram comparados com a aplicação do método analítico da pseudo-inversa e ambos os resultados estão disponíveis a seguir:

TABLE I
RESULTADOS DAS MÉTRICAS POR DIVISÃO COM PSEUDO-INVERSA

Divisão	Erro Médio Quadrático (MSE)	Coeficiente de Person
Divisão 1	0.9710	0.5277
Divisão 2	0.4366	0.5703
Divisão 3	0.3966	0.8816
Divisão 4	0.4131	0.7249
Divisão 5	0.5283	0.6498
Média Final	0.5491 ± 0.2158	0.6709 ± 0.1252

TABLE II
RESULTADOS DAS MÉTRICAS POR DIVISÃO COM ADALINE (15.000 ÉPOCAS

Divisão	Erro Médio Quadrático (MSE)	Coeficiente de Person
Divisão 1	0.9710	0.5277
Divisão 2	0.4366	0.5703
Divisão 3	0.3966	0.8816
Divisão 4	0.4131	0.7249
Divisão 5	0.5283	0.6498
Média Final	0.5490 ± 0.2158	0.6709 ± 0.1252

TABLE III
RESULTADOS EM COMPARAÇÃO COM NÚMERO DE ÉPOCAS

Número de épocas	Erro Médio Quadrático (MSE)	Coeficiente de Person
100	0.8664 ± 0.2733	0.5398 ± 0.2139
500	0.6133 ± 0.2332	0.6619 ± 0.1430
1000	0.5519 ± 0.2169	0.6746 ± 0.1269
5000	0.5468 ± 0.2159	0.6726 ± 0.1247
10000	0.5487 ± 0.2158	0.6711 ± 0.1252
15000	0.5490 ± 0.2158	0.6709 ± 0.1252

VI. CONCLUSÃO

Ao treinar com 15.000 épocas, pode se observar que o Adaline convergiu para valores bem próximos aos obtidos pela solução analítica da Pseudo-inversa. Este fenômeno demonstra que o algoritmo de Gradiente Descendente, embora iterativo, é capaz de alcançar o mínimo global da função de custo quadrática, desde que lhe seja permitido tempo de processamento suficiente para o ajuste fino dos pesos w .

O Notebook do Colab deste trabalho está disponível na URL a seguir: Nycksandro_Lima_Trabalho01

REFERENCES

- [1] A. Shrivastava, M. Chakkaravarthy, and M. A. Shah, "A new machine learning method for predicting systolic and diastolic blood pressure using clinical characteristics," *Healthcare Analytics*, vol. 4, p. 100219, 2023.
- [2] Y. Y. Hsieh, C. D. Wu, S. S. Lu, and Y. Tsao, "A linear regression model with dynamic pulse transit time features for noninvasive blood pressure prediction," in *Proc. IEEE Biomedical Circuits and Systems Conference (BioCAS)*. IEEE, 2016, pp. 604–607.
- [3] C. F. F. Costa, "Divisão de dados: Validação cruzada," Notas de aula da disciplina de Inteligência Artificial Aplicada, Universidade Federal do Amazonas (UFAM), Amazonas, Brasil, 2026.
- [4] Wikipedia contributors, "Minimum mean square error estimator," 2026, [Online; acessado em 28-março-2026]. [Online]. Available: https://en.wikipedia.org/wiki/Minimum_mean_square_error_estimator
- [5] —, "Coeficiente de correlação de pearson," 2026, [Online; acessado em 28-março-2026]. [Online]. Available: https://pt.wikipedia.org/wiki/Coeficiente_de_correlao_de_Pearson