

Trabalho 2: Classificadores Lineares

1st Nycksandro Lima dos Santos
Instituto de Computação
Universidade Federal do Amazonas
Manaus, Brasil
nycksandro.santos@icomp.ufam.edu.br

Abstract—Este trabalho apresenta a aplicação de um classificador linear baseado em Regressão Logística para a detecção de câncer de ovário a partir de dados de espectrometria de massa. O conjunto de dados compreende perfis proteômicos de 216 pacientes, com 100 variáveis de intensidade de íons cada. A metodologia consistiu na implementação de um regressor de camada única, com a divisão dos dados em 80% para treinamento e 20% para teste. O modelo foi avaliado com base em métricas de acurácia, sensibilidade e especificidade, visando analisar a eficácia de métodos lineares na identificação de biomarcadores oncológicos. Os resultados demonstram o potencial do aprendizado de máquina como ferramenta de suporte ao diagnóstico clínico.

Index Terms—Regressão Logística, Câncer de Ovário, Espectrometria de Massa, Classificadores Lineares, Aprendizado de Máquina.

I. INTRODUÇÃO

O câncer de ovário apresenta um desafio diagnóstico significativo devido à sua natureza assintomática em estágios iniciais. A espectrometria de massa surge como uma ferramenta promissora, permitindo a análise de perfis proteômicos complexos. Este trabalho propõe a utilização de um classificador linear, especificamente a Regressão Logística, para processar intensidades de íons e categorizar pacientes entre saudáveis e portadores da patologia. O objetivo é avaliar a viabilidade de modelos lineares simples na identificação de padrões em dados de alta dimensionalidade.

II. TRABALHOS SIMILARES

Foi realizada uma breve busca por trabalhos similares na literatura e foi selecionado o seguinte artigo:

A. Using machine learning to predict ovarian cancer

No estudo conduzido por Lu et al. [1], a Regressão Logística foi aplicada como um método estatístico para analisar variáveis independentes e determinar desfechos dicotômicos em pacientes com câncer de ovário. Os autores destacam que o modelo foi ajustado para prever a probabilidade do desfecho, utilizando a matriz de confusão como ferramenta base para o cálculo de métricas de desempenho. De forma análoga ao presente relatório, a pesquisa de Lu et al. priorizou a análise de Sensibilidade, Especificidade e Acurácia, reforçando a robustez desses indicadores na avaliação de modelos preditivos em contextos clínicos.

III. BASE DE DADOS

As bases de dados consistem em perfis proteômicos obtidos por espectrometria de massa, organizados em dois conjuntos principais:

- ovarianInputs: Matriz de 216×100, onde cada linha representa um paciente e cada coluna a intensidade de íons para um valor específico de massa-carga.
- ovarianTargets: Matriz de 216×2, utilizando codificação one-hot encoding para as classes: Câncer [1,0] e Normal [0,1].

A base possui um leve desbalanceamento, com 121 instâncias positivas (câncer) e 95 negativas (normais).

	0.462901	0.406736	0.306215	0.488105	0.175169	0.356551	0.439552	0.246779	1.373469	1.571959	...
0	0.370565	0.306431	0.239715	0.476358	0.175900	0.353762	0.476071	0.258894	1.338965	1.677094	...
1	0.461550	0.278980	0.206608	0.744342	0.152133	0.247645	0.304292	0.170356	1.047475	1.193578	...
2	0.375149	0.287317	0.241130	0.426810	0.205859	0.208770	0.283752	0.152572	1.213785	1.510149	...
3	0.113849	0.108411	0.086275	0.219954	0.050794	0.116163	0.188402	0.069726	0.705930	0.815952	...
4	0.233627	0.117294	0.059205	0.284276	0.047048	0.220356	0.282986	0.162463	0.917090	1.045686	...

5 rows × 100 columns

Fig. 1. As primeiras 5 linhas da base de dados ovarianInputs

IV. METODOLOGIA




Fig. 2. Fluxograma da metodologia adotada para o trabalho prático.

A. Pré-processamento dos dados

1) *Limpeza de Colunas*: A base de dados ovarianTargets apresentava originalmente duas colunas em formato one-hot encoding, as quais continham informações mutuamente exclusivas e redundantes. Para a otimização do treinamento e redução da dimensionalidade do alvo, uma das colunas foi removida. O problema foi tratado, portanto, como uma

classificação binária simples, onde o rótulo [1] representa a presença de câncer e [0] representa a normalidade, eliminando a redundância de dados sem perda de informação estatística.

2) Normalização:

a) *Normalização da base de dados ovarianInputs*: Considerando que os dados de espectrometria de massa apresentam intensidades de íons com ordens de magnitude variadas, aplicou-se a técnica de normalização Min-Max. O algoritmo transforma cada característica individualmente, escalonando-as para o intervalo [0,1] através da fórmula:

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}} \quad (1)$$

Este procedimento impede que variáveis com magnitudes numericamente superiores dominem o cálculo dos pesos do regressor de forma desproporcional, garantindo que todos os 100 valores de massa-carga contribuam equitativamente para a fronteira de decisão.

b) *Normalização da base de dados ovarianTargets*: Os rótulos das classes foram definidos como 1 (Câncer) e -1 (Saudável). Esta codificação bipolar foi preferida em relação ao padrão 0,1 para garantir uma diferenciação mais clara entre as classes durante o treinamento do modelo.

B. Divisão do Dataset

A divisão do dataset foi realizada seguindo a distribuição 80-20 (Treino-Teste).

Como cada uma das bases de dados possuem 216 registros, a divisão foi realizada da seguinte maneira:

$$qntTreino = 80\% \cdot qntTotal \quad (2)$$

$$qntTeste = qntTotal - qntTreino \quad (3)$$

Sendo:

- qntTotal: quantidade total de registros na base de dados
- qntTreino: quantidade de registros da partição de Treino
- qntTeste: quantidade de registros da partição de Teste

Agora substituindo pelos valores correspondentes:

$$qntTreino = 80\% \cdot 216 = 172 \quad (4)$$

$$qntTeste = 216 - 172 = 43 \quad (5)$$

Dessa forma, a partição de cada uma das bases de dados possuem 172 registros na partição de treino e 43 registros na partição de teste.

C. Treinamento

O treinamento do classificador foi realizado utilizando a biblioteca Scikit-Learn.

O processo de ajuste consistiu em:

- Execução do Ajuste (fit): O modelo processou as intensidades de íons para calcular os pesos necessários para distinguir as classes 1 (Câncer) e -1 (Saudável).

- Otimização: O algoritmo buscou a fronteira de decisão que melhor separa as amostras, minimizando o erro de classificação.
- Generalização: Graças à regularização nativa do LogisticRegression, o modelo evitou o sobreajuste, resultando em um desempenho consistente com 95,3% de acurácia nos dados de teste.

D. Cálculo das métricas

1) *Acurácia*: Proporção de casos do conjunto de teste que resultou numa saída correta

$$\frac{TP + TN}{TP + FP + TN + FN} \quad (6)$$

2) *Sensibilidade*: Fração de casos positivos, que foram reportados como positivos

$$\frac{TP}{TP + FN} \quad (7)$$

3) *Especificidade*: Fração de casos negativos que o algoritmo reportou como negativos.

$$\frac{TN}{TN + FP} \quad (8)$$

Onde:

- TP: True Positive (Verdadeiro Positivo)
- TN: True Negative (Verdadeiro Negativo)
- FP: False Positive (Falso Positivo)
- FN: False Negative (Falso Negativo)

Fonte: [2]

V. RESULTADOS

TABLE I
RESULTADOS DAS MÉTRICAS OBTIDAS

Métrica	Valor Obdido (%)
Acurácia	95.35
Sensibilidade	95.24
Especificidade	95.45

A. Matriz de confusão




Fig. 3. Matriz de confusão resultante da aplicação de regressão logística

VI. CONCLUSÃO

O classificador linear baseado em Regressão Logística apresentou um desempenho robusto na identificação de câncer de ovário, atingindo uma acurácia de 95,3% no conjunto de teste.

A análise das métricas revelou um equilíbrio fundamental para aplicações diagnósticas:

- Sensibilidade (95,2%): Garante que a vasta maioria dos pacientes com patologia seja identificada, minimizando o risco clínico de falsos negativos.
- Especificidade (95,4%): Assegura uma baixa taxa de alarmes falsos, evitando procedimentos médicos invasivos desnecessários em pacientes saudáveis

A matriz de confusão, com apenas um Falso Positivo (FP) e um Falso Negativo (FN), confirma que a codificação bipolar (-1,1) e a normalização Min-Max foram eficazes em preparar os dados para o regressor.

O Notebook do Colab deste trabalho está disponível na URL a seguir: Nycksandro_Lima_Trabalho02

REFERENCES

- [1] M. Lu, Z. Fan, B. Xu, L. Chen, X. Zheng, J. Li, T. Znati, Q. Mi, and J. Jiang, "Using machine learning to predict ovarian cancer," *International journal of medical informatics*, vol. 141, p. 104195, 2020.
- [2] C. F. F. Costa, "Aprendizado de máquina: Métricas de desempenho," Notas de aula da disciplina de Inteligência Artificial Aplicada, Universidade Federal do Amazonas (UFAM), Amazonas, Brasil, 2026.