

Trabalho 3: Árvores de Decisão

1st Nycksandro Lima dos Santos
Instituto de Computação
Universidade Federal do Amazonas
Manaus, Brasil
nycksandro.santos@icomp.ufam.edu.br

Abstract—Este trabalho aplica o algoritmo Random Forest para a predição da temperatura máxima diária na cidade de Seattle, utilizando dados históricos do clima. Foram usadas cinco variáveis preditoras relacionadas a condições meteorológicas passadas e médias históricas. O desempenho dos modelos foi avaliado por meio do erro absoluto médio (MAE) e do erro quadrático médio (MSE), além da análise da importância das variáveis.

Index Terms—Árvore de decisão, Predição de Temperatura, Previsão do Tempo, Regressão, Aprendizado de Máquina.

I. INTRODUÇÃO

O presente trabalho tem como objetivo aplicar técnicas de aprendizado de máquina, com foco em árvores de decisão do tipo Random Forest, para a predição da temperatura máxima diária na cidade de Seattle.

A partir de um conjunto de dados contendo aproximadamente seis anos de informações meteorológicas, busca-se construir modelos capazes de estimar a variável alvo (actual) com base em atributos históricos relevantes.

O desempenho dos modelos foi mensurado por meio das métricas de erro absoluto médio (MAE) e erro quadrático médio (MSE), possibilitando a comparação entre diferentes configurações. Adicionalmente, foi analisada a importância relativa das variáveis, com o intuito de identificar quais fatores exercem maior influência na predição da temperatura.

II. TRABALHOS SIMILARES

Foi realizada uma breve busca por trabalhos similares na literatura e foi selecionado o seguinte artigo:

A. *Weather prediction using random forest machine learning model*

Este estudo [1] investiga a utilização do aprendizado de máquina, especificamente o algoritmo Random Forest, para prever a radiação solar e a velocidade do vento no estado de Tamil Nadu, na Índia. A pesquisa justifica-se pela complexidade dos modelos climáticos tradicionais em sistemas tropicais e pelo alto custo de instrumentos de medição física. Ao comparar diferentes métodos, os autores demonstram que o modelo de floresta aleatória supera as regressões estatísticas e as máquinas de vetores de suporte em precisão. Os resultados permitiram a criação de mapas de recursos sazonais, fundamentais para a gestão eficiente de redes de energia renovável. Conclui-se que a inteligência artificial oferece uma alternativa viável e econômica para previsões meteorológicas, mesmo sem um conhecimento profundo da física atmosférica.

III. BASE DE DADOS

Tabela 1: Cinco registros extraídos da tabela *extended.xlsx*

	year	month	day	weekday	ws_1	prcp_1	snwd_1	temp_2	temp_1	average	actual	friend
0	2011	1	1	Sat	4.92	0.00	0	36	37	45.6	40	40
1	2011	1	2	Sun	5.37	0.00	0	37	40	45.7	39	50
2	2011	1	3	Mon	6.26	0.00	0	40	39	45.8	42	42
3	2011	1	4	Tues	5.59	0.00	0	39	42	45.9	38	59
4	2011	1	5	Wed	3.80	0.03	0	42	38	46.0	45	39

Fig. 1. As primeiras 5 linhas da base de dados *extended.xlsx*

A base de dados utilizada no trabalho prático se consiste no agrupamento de 6 anos de informações do clima da cidade de Seattle, detalhando desde a velocidade média do vento um dia antes, até histórico de média de temperaturas máximas:

Algumas informações sobre a base de dados:

- Número de linhas: 2196
- Número de colunas: 12
- Colunas:
 - year
 - month
 - day
 - weekday
 - ws_1
 - prcp_1
 - snwd_1
 - temp_2
 - temp_1
 - average
 - actual
 - friend

IV. METODOLOGIA




Fig. 2. Fluxograma da metodologia adotada para o trabalho prático.

A. Pré-processamento dos dados

1) *Limpeza de Colunas*: Utilização do método “dropna()” da biblioteca pandas para excluir linhas que possuam algum valor vazio.

2) *Separação das variáveis de predição*: As variáveis a seguir serão utilizadas como variáveis de predição:

- year: ano em que o registro ocorreu
- ws_1: velocidade média do vento um dia antes
- temp_2: temperatura máxima dois dias antes
- temp_1: temperatura máxima um dia antes
- average: histórico de média de temperaturas máximas

3) *Variável predita*: A variável “actual” corresponde a temperatura máxima verificada no dia e será a variável predita.

B. Divisão do Dataset

A divisão do dataset foi realizada seguindo a distribuição 75-15 (Treino-Teste).

A base de dados *temps_extended.xlsx* possui 2191 linhas.

$$qntTreino = 75\% \cdot qntTotal \quad (1)$$

$$qntTeste = qntTotal - qntTreino \quad (2)$$

Sendo:

- qntTotal: quantidade total de registros na base de dados
- qntTreino: quantidade de registros da partição de Treino
- qntTeste: quantidade de registros da partição de Teste

Agora substituindo pelos valores correspondentes:

$$qntTreino = 75\% \cdot 2191 = 1643 \quad (3)$$

$$qntTeste = 2191 - 1643 = 548 \quad (4)$$

Dessa forma, a partição de treino da base de dados possuirá 1643 registros na partição de treino e 548 registros na partição de teste.

C. Treinamento

Foram carregados 3 modelos de *Random Forest* do Scikit-Learn e nomeados respectivamente de Modelo 1, Modelo 2 e Modelo 3. Cada um desses modelos foram configurados com hiperparâmetros distintos que serão detalhados a seguir:

- Modelo 1:
 - bootstrap = True
 - max_depth = 5
 - min_samples_leaf = 1
 - min_samples_split = 2
 - n_estimator = 200
- Modelo 2:
 - bootstrap = True
 - max_depth = 40
 - min_samples_leaf = 4
 - min_samples_split = 10
 - n_estimator = 400
- Modelo 3:
 - bootstrap = False
 - max_depth = 20
 - min_samples_leaf = 2
 - min_samples_split = 5
 - n_estimator = 600

Após a configuração dos hiperparâmetros, todos os modelos foram treinados com as mesmas partições de Treinamento.

D. Cálculo das métricas

Para a avaliação desses modelos, foram selecionadas duas métricas: Erro Absoluto Médio e Erro Médio Quadrático.

1) *Erro Absoluto Médio (Mean Absolute Error – MAE)*: quantifica a performance do modelo calculando a média aritmética dos valores absolutos das diferenças entre os valores reais (y) e as saídas estimadas ($\hat{y}$). Matematicamente, o MAE é definido pela equação:

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \quad (5)$$

Fonte: [2]

2) *Erro Médio Quadrático (Mean Square Error – MSE)*: quantifica a performance do modelo calculando a média aritmética dos quadrados das diferenças entre os valores reais (y) e as saídas estimadas ($\hat{y}$). Matematicamente, o MSE é definido pela equação

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (6)$$

Fonte: [3]

V. RESULTADOS

TABLE I
ERRO ABSOLUTO MÉDIO (MAE) E ERRO QUADRÁTICO MÉDIO (MSE)
DOS MODELOS

Modelo	MAE	MSE
Modelo 1	4.151	28.845
Modelo 2	4.427	34.131
Modelo 3	4.697	37.796

TABLE II
IMPORTÂNCIA DAS VARIÁVEIS NO MODELO 1

Variáveis	Importância (%)
temp_1	37.07
average	25.35
temp_2	19.56
ws_1	12.52
year	05.47

TABLE III
IMPORTÂNCIA DAS VARIÁVEIS NO MODELO 2

Variáveis	Importância (%)
temp_1	24.93
average	24.66
ws_1	19.58
temp_2	19.27
year	11.54

TABLE IV
IMPORTÂNCIA DAS VARIÁVEIS NO MODELO 3

Variáveis	Importância (%)
average	25.09
temp_1	21.58
ws_1	21.50
temp_2	18.99
year	12.81

VI. CONCLUSÃO

Os resultados indicam que o Modelo 1 apresentou o melhor desempenho, alcançando os menores valores de MAE (4.151) e MSE (28.845), o que não implica necessariamente maior capacidade de generalização em termos absolutos, mas, no contexto do conjunto de dados de Seattle, representa um desempenho superior em relação aos demais modelos. Os Modelos 2 e 3 apresentaram erros progressivamente maiores,

sugerindo possível sobreajuste ou configurações de hiperparâmetros menos adequadas ao tamanho e às características do conjunto de dados.

A análise de importância das variáveis mostrou que “temp_1” e “average” foram os atributos mais relevantes para a predição da temperatura, evidenciando a forte dependência temporal do fenômeno. Já a variável “year” apresentou menor contribuição em todos os modelos.

Dessa forma, conclui-se que configurações mais simples do Random Forest podem apresentar melhor desempenho neste tipo de problema, especialmente quando o conjunto de dados possui estrutura temporal bem definida e número limitado de variáveis e de dados relevantes.

O Notebook do Colab deste trabalho está disponível na URL a seguir: Nycksandro_Lima_Trabalho03

REFERENCES

- [1] R. Meenal, P. A. Michael, D. Pamela, and E. Rajasekaran, “Weather prediction using random forest machine learning model,” *Indonesian Journal of Electrical Engineering and Computer Science*, vol. 22, no. 2, pp. 1208–1215, 2021.
- [2] Wikipedia contributors, “Mean absolute error,” https://en.wikipedia.org/wiki/Mean_absolute_error, 2026, acesso em: 5 maio 2026.
- [3] C. F. F. Costa, “Aprendizado de máquina: Métricas de desempenho,” Notas de aula da disciplina de Inteligência Artificial Aplicada, Universidade Federal do Amazonas (UFAM), Amazonas, Brasil, 2026.