

Trabalho 5: Redes Convolutivas

1st Nycksandro Lima dos Santos
Instituto de Computação
Universidade Federal do Amazonas
Manaus, Brasil
nycksandro.santos@icomp.ufam.edu.br

I. PROBLEMA

A base de dados ORL (Laboratório de Pesquisa da Olivetti) contém 10 imagens diferentes de cada 40 indivíduos, totalizando 400 imagens de tamanho 92x112 pixels. Para alguns indivíduos, as imagens foram capturadas em diferentes épocas, variando em iluminação, expressões faciais (olhos abertos e fechados, sorrindo ou não) e com detalhes na face (com ou sem óculos). Todas as imagens foram capturadas com um fundo negro homogêneo. Esta base pode ser encontrada na pasta da disciplina e no site: Att Database of Faces. Pretende-se nesse trabalho fazer o reconhecimento das faces dos indivíduos dessas bases de dados com uma rede convolutiva.

II. BASE DE DADOS

Esse dataset é conhecido como “Database of Faces” (antigamente chamado de ORL Database of Faces) e foi criado pela AT&T Laboratories Cambridge para estudos de reconhecimento facial.

Ele contém um conjunto relativamente pequeno, porém bem estruturado, de imagens de rostos humanos usadas em pesquisa acadêmica.

A. Estrutura do Dataset

40 indivíduos (sujeitos distintos) 10 imagens por pessoa, totalizando 400 imagens

Cada sujeito aparece em uma pasta separada (s1, s2, ..., s40). Dentro de cada pasta, há arquivos de imagem numerados de 1 a 10.

B. Características das imagens

As fotos foram capturadas entre 1992 e 1994, em ambiente de laboratório, com condições relativamente controladas:

- Fundo escuro e uniforme
- Posição frontal do rosto (com pequenas variações laterais)
- Variações entre imagens do mesmo indivíduo:
- Expressões faciais (sorrindo / neutro)
- Olhos abertos ou fechados
- Uso ou não de óculos
- Pequenas mudanças de iluminação
- Pequenos deslocamentos de pose
- Formato e especificações
- Formato: PGM (Portable Gray Map)
- Imagens em tons de cinza (grayscale)
- Resolução: 92 × 112 pixels
- Níveis de cinza: 256 (8 bits)

C. Adaptações

Para a utilização da biblioteca do Keras, foi necessário converter todas as imagens que originalmente estavam no formato “PGM” para o formato “PNG”.

D. Divisão da Base de Dados

A base original de dados possuía 400 imagens e foi dividida na proporção 70% (280) para partição de Treinamento e 30% (120 imagens) para partição de Teste.

III. ARQUITETURA DA REDE

A. Modelo 1

O modelo 1 possui a seguinte arquitetura:

- 1) CONV
- 2) BATCH
- 3) RELU
- 4) POOLING
- 5) FULLCONNECT
- 6) SOFTMAX
- 7) CLASSIFIER

A arquitetura pode ser ilustrada pela figura a seguir:




Fig. 1: Diagrama da Arquitetura do Modelo 01

B. Modelo 2

O modelo 2 possui a seguinte arquitetura:

- 1) (CONV, BATCH, RELU, POOLING) x 3
- 2) FULLCONNECT
- 3) SOFTMAX
- 4) CLASSIFIER

A arquitetura pode ser ilustrada pela figura a seguir:




Fig. 2: Diagrama da Arquitetura do Modelo 01

IV. HIPERPARÂMETROS

Ambos os modelos foram configurados com os hiperparâmetros a seguir:

- Learning rate: 1×10^{-4}
- Batch size: 16
- Epochs: 75
- Optimizer: Adam
- Patience: 50
- Loss = sparse_categorical_crossentropy

V. CÓDIGO

A simulação foi realizada utilizando o seguinte código (versão simplificada) em Python. Os detalhes da implementação estão disponíveis em: Nycksandro_Lima_Trabalho05.

```
#Modelo 1: CONV-BATCH-RELU-POOLING-
FULLCONNECT-SOFTMAX-CLASSIFIER

modelo_1 = Sequential([
    layers.Input(shape=(112, 92, 1)),

    layers.Conv2D(32, (3,3), padding='same'), # CONV
    layers.BatchNormalization(), # BATCH
    layers.ReLU(), # RELU
    layers.MaxPooling2D((2,2)), # POOLING

    # FULLCONNECT
    layers.Flatten(),

    layers.Dense(256),
    layers.ReLU(),
    layers.Dropout(0.5),

    layers.Dense(40, activation='softmax') # SOFTMAX
])

modelo_1.summary()

# Modelo 2

# CONV-BATCH-RELU-POOLING-
CONV-BATCH-RELU-POOLING-
CONV-BATCH-RELU-POOLING-
FULLCONNECT-SOFTMAX CLASSIFIER

modelo_2 = Sequential([
    layers.Input(shape=(112, 92, 1)),

    # Bloco 1
    layers.Conv2D(32, (3,3), padding='same'), # CONV
    layers.BatchNormalization(), # BATCH
    layers.ReLU(), # RELU
    layers.MaxPooling2D((2,2)), # POOLING

    # Bloco 2
    layers.Conv2D(64, (3,3), padding='same'), # CONV
    layers.BatchNormalization(), # BATCH
    layers.ReLU(), # RELU
    layers.MaxPooling2D((2,2)), # POOLING

    # Bloco 3
    layers.Conv2D(128, (3,3), padding='same'), # CONV
    layers.BatchNormalization(), # BATCH
    layers.ReLU(), # RELU
    layers.MaxPooling2D((2,2)), # POOLING

    # Fully Connected
    layers.Flatten(),
    layers.Dense(256),
    layers.ReLU(),
    layers.Dropout(0.5),
    layers.Dense(40, activation='softmax') # SOFTMAX
])

modelo_2.summary()
```

```
# Classificador
layers.Dense(NUM_CLASSES, activation='softmax') # SOFTMAX
])

modelo_2.summary()

# Configurando a callback para restaurar os melhores pesos e ter paciência = 30 e 50
callback_model1 = tf.keras.callbacks.EarlyStopping(
    monitor='val_loss',
    patience=50,
    restore_best_weights=True)

callback_model2 = tf.keras.callbacks.EarlyStopping(
    monitor='val_loss',
    patience=50,
    restore_best_weights=True)

# Configurando os compile de ambos os modelos
modelo_1.compile(
    optimizer=tf.keras.optimizers.Adam(learning_rate=1e-4),
    loss='sparse_categorical_crossentropy', # Para ter de 0-39 classes (40 pessoas)
    metrics=['accuracy'])

modelo_2.compile(
    optimizer=tf.keras.optimizers.Adam(learning_rate=1e-4),
    loss='sparse_categorical_crossentropy', # Para ter de 0-39 classes (40 pessoas)
    metrics=['accuracy'])

# Treinamento do modelo 1
historico_1 = modelo_1.fit(train_ds,
    validation_data=valid_ds,
    epochs=75,
    callbacks=callback_model1)

# Treinamento do modelo 2
historico_2 = modelo_2.fit(train_ds,
    validation_data=valid_ds,
    epochs=75,
    callbacks=callback_model2)
```

VI. RESULTADOS

A. Modelo 1

Os resultados de treino demonstram uma convergência ideal e alta capacidade de generalização. Um ponto de destaque é o fato de a acurácia de teste ter se mantido superior à de treino até a época 40. No momento do teste, a rede opera com sua capacidade total, elevando a precisão inicial. Após a época 40, ambas as curvas de acurácia e perda se estabilizam de forma síncrona (acurácia em 95% e perda em 0.15), consolidando o aprendizado definitivo da rede sem sinais de overfitting.

- Acurácia




Fig. 3: Acurácia do Modelo 01 ao longo do Treinamento

- Perda




Fig. 4: Perda do Modelo 01 ao longo do Treinamento




Fig. 6: Perda do Modelo 02 ao longo do Treinamento

B. Modelo 2

O Modelo 2 apresentou um comportamento de aprendizado tardio no conjunto de teste, caracterizado por estabilidade inicial na acurácia e uma elevação temporária da perda (Loss Hump) até aproximadamente a época 15. A partir da época 20, observa-se uma convergência abrupta e bem-sucedida: a acurácia de teste estabiliza-se em patamares elevados (98%) e a perda é mitigada, demonstrando excelente capacidade de generalização e resiliência contra o sobreajuste definitivo graças às camadas de regularização..

• Acurácia




Fig. 5: Acurácia do Modelo 02 ao longo do Treinamento

• Perda

TABLE I: Comparação de Desempenho entre as Arquiteturas Avaliadas

Modelo	Acurácia (Accuracy)	Perda (Loss)
Modelo 1	0,9750	0,0975
Modelo 2	0,9917	0,0613

VII. MATRIZ DE CONFUSÃO

As Matrizes de Confusão ratificaram o excelente desempenho sugerido pelas curvas de aprendizado. Ambos os modelos exibiram uma forte concentração de acertos ao longo da diagonal principal, o que atesta a alta precisão da rede no problema de classificação multiclasse (40 classes).

O Modelo 1 demonstrou robustez ao gabaritar a maioria das categorias com a pontuação máxima, registrando apenas três episódios isolados de falsos-positivos (nas classes reais 0, 1 e 28). Por sua vez, o Modelo 2 (arquitetura mais profunda) demonstrou superioridade ao mitigar quase por completo essas ambiguidades, consolidando uma diagonal praticamente perfeita. Esse comportamento atesta que o acréscimo de blocos convolucionais expandiu a capacidade do Modelo 2 de discriminar feições complexas e atingir uma generalização de excelência na base de testes.

A. Modelo 01




Fig. 7: Matriz de Confusão do Modelo 01

B. Modelo 02




Fig. 8: Matriz de Confusão do Modelo 02

O Notebook do Colab deste trabalho está disponível na URL a seguir: Nycksandro_Lima_Trabalho05

REFERENCES